

NYC Motor Vehicle Collisions

Analyse von Unfall-Daten in New York City

DataPy // Prof. Bießmann & Prof. Ipek-Ugay

Datensatz:

- **Herkunft:** Offizielles US-Behördenportal (Data.gov)

[<https://catalog.data.gov/dataset/motor-vehicle-collisions-crashes>]

- **Art der Daten:** Alle polizeilich erfassten Verkehrsunfälle in New York City (Zeitraum 2012 bis heute)

- **Zentrale Merkmale im Datensatz:**

- *Zeit & Ort:* Datum, Uhrzeit, Stadtteil (Borough), exakte GPS-Koordinaten
- *Kontext:* Unfallursachen (z. B. Ablenkung), beteiligte Fahrzeugtypen
- *Auswirkungen:* Anzahl der verletzten oder getöteten Personen

Probleme der Rohdaten:

- **Falsche Formate:** Datums- und Uhrzeitspalten waren als reiner Text hinterlegt. Viele Text Spalten als „Object“-Datentyp
- **Große Lücken:** Viele fehlende Werte (NaN) bei den GPS-Koordinaten und Stadtteilen.
- **Fehlende Daten:** Ungenaue oder nichtssagende Einträge wie 'UNSPECIFIED' oder 'UNKNOWN' bei den Unfallursachen.
- **Schreibfehler:** Doppelte Bezeichnungen bei Fahrzeugtypen (z. B. "TAXI" und "Taxi").

Data-Cleaning

- **Typ-Konvertierung:** Umwandlung von CRASH DATE in ein echtes, berechenbares Datumsformat (datetime64).
- **Text-Bereinigung:** Zusammenführung von falsch geschriebenen Fahrzeugtypen und Vereinheitlichung der Schreibweisen.
- **GPS-Daten prüfen:** Koordinaten die außerhalb von NYC liegen werden auf NaN gesetzt.
- **Vereinheitlichung:** Angaben wie 'UNSPECIFIED' oder 'UNKNOWN' und offensichtlich falsche Daten werden auf pandas.NA gesetzt.

Optimierung der Daten:

- **Neue Spalten:** ‚CRASH HOUR‘ und ‚WEEKDAY‘
- **Typ-Vereinheitlichung:** Umwandlung aller Textspalten in den Pandas-Datentyp string.
- **Implizite Daten einfügen:** Bei leeren 'NUMBER OF PEOPLE INJURED/KILLED' Zeilen wird 0 angenommen.

Wichtige Visualisierungen:

- **Hauptunfallursachen:**

- Visuelle Darstellung der Top-20-Ursachen. *Ergebnis:* "Driver Inattention/Distraktion" (Ablenkung) ist mit weitem Abstand die häufigste Ursache.

- **Beteiligte Fahrzeuge:**

- SUVs und Sedans (Limousinen) dominieren die Unfallstatistik.

Visualisierungen Erkenntnisse:

- **Wochentag-Uhrzeit-Heatmap:**

- *Unter der Woche:* Unfälle häufen sich in den klassischen Rush-Hours (morgens um 08:00 Uhr und nachmittags zwischen 16:00 und 17:00)

- **Der Saisonale Verlauf:**

- Die Unfallkurve bleibt über das Jahr hinweg relativ flach. Das Wetter (wie Winter oder Schnee) hat statistisch einen geringeren Einfluss auf die Unfallmenge als gedacht.